

N° d'ordre :...../..../



Université Cadi Ayyad Ecole Nationale des Sciences Appliquées de Safi Département Informatique, Réseaux et Télécommunications (IRT)

MEMOIRE de PROJET DE FIN D'ETUDES

pour l'obtention du diplôme :

INGENIEUR D'ETAT

en Génie Informatique

ANALYSE DES SENTIMENTS ET
DETECTION EMOTIONNELLE DES
TEXTES SUR LES RESEAUX
SOCIAUX DE CGI MAROC



Réalisé Par Noura SOUAIDI

Effectué à CGI- Casablanca

Dr. Ali CHOUKRI	Mr. Ahmed AINOUZ
Encadré à l'ENSAS par :	Encadré à CGI par :

	Soutenu le/06/2019 d	evant le jury composé de :
Mr	······,	Professeur à l'ENSA de Safi
Mr		Professeur à l'ENSA de Safi

بسم اللي الرفح الرفيم

وَقُلْ اعْمَلُوا فَسَيَرَى اللَّهُ عَمَلَكُمْ وَرَسُولُهُ وَالْمُؤْمِنُونَ - التوبة - التوبة -

Remerciements

Je remercie le tout puissant de m'avoir donné le courage et la volonté d'achever ce travail et sans Lequel il n'aurait jamais été accompli.

Mes remerciements les plus sincères, accompagnés de toute ma gratitude vont tout d'abord au corps professoral de l'*Ecole Nationale Des Sciences Appliquées à Safi* (ENSAS), et particulièrement les professeurs qui interviennent dans la filière Génie Réseaux et Télécommunications (GTR), pour leurs conseils, leurs disponibilités et leurs bienveillances.

Je tiens à exprimer ma profonde gratitude à mon encadrant de l'ENSAS, Dr. Ali CHOUKRI, pour sa disponibilité et son engagement au profit du bon déroulement de mon travail.

Je tiens également particulièrement à témoigner toute ma reconnaissance à mon encadrant Mr. Ahmed AINOUZ pour m'avoir proposé ce projet, pour les conseils qu'il n'a cessé de me prodiguer et surtout pour la confiance qu'il m'a accordé pour sa réalisation.

Je remercie par la même occasion tous les membres du jury pour avoir accepté d'évaluer mon travail.

Enfin, mes remerciements vont à tous ceux et celles qui ont contribué de près ou de loin à l'accomplissement de ce travail.

Table des abbreviations

NLTK = Natural Language Toolkit

API = Application Programming Pnterface

GTO = Global Technology Operation

NRC = Norwegian Refugee Council

Résumé

Le projet présent a pour cible d'acclimater un système d'analyse sentimentale et émotionnel de l'information textuelle sur le réseau social « Facebook » de CGI Maroc afin de répondre aux nouveaux enjeux en termes de satisfaction de la clientèle. L'étude devra prendre en considération les traitements des données massives ayant comme référentiel les réseaux sociaux et le conditionnement de travail pour assurer la continuité de fonctionnement et la fluidité du produit.

Afin de mener à bien cette mission, nous commencerons par une documentation sur la big data en déterminant ses différents outils et sa fonctionnalité Puis, nous dresserons une étude sur les réseaux sociaux ayant plus d'influence sur le publique, et les outils dédiés à ce type de recherche du big data, nous somme basé sur un langage de programmation et un outil de développement open source retenu au cours de notre documentation. Par la suite nous avons généralisé notre réalisation pour mettre en évidence la fluidité des paramètres d'étude.

Finalement nous avons réalisé une planification pour la réalisation de la deuxième partie de notre projet, de l'outil d'intelligence choisi pour assurer le bon fonctionnement de cette phase.

Abstract

The current project aims to acclimate a system of sentimental and emotional analysis of textual information on the social network "Facebook" of CGI Morocco to meet new challenges in terms of customer satisfaction. The study will have to take into consideration the massive data processing having as reference the social networks and the working conditioning to ensure the continuity of operation and the fluidity of the product.

In order to carry out this mission, we will begin with a documentation on the big data by determining its various tools and its functionality Then, we will draw up a study on the social networks having more influence on the public, and the tools dedicated to it. type of big data research, we are based on a programming language and an open source development tool selected during our documentation. Subsequently we have generalized our realization to highlight the fluidity of study parameters.

Finally we realized a planning for the realization of the second part of our project, of the intelligence tool chosen to ensure the good functioning of this phase.

Table des matières

	1
Remerciements	4
Table des abbreviations	5
Résumé	6
Abstract	7
Table des matières	8
Table des figures	9
Dédicaces	10
Introduction générale	11
Chapitre 1 : Contexte générale du projet	12
Présentation de l'entreprise d'accueil :	12
I. Introduction	12
II. Présentation de CGI technologies et solutions	12
1. Présentation générale :	12
3. Clients de CGI :	14
4. CGI Maroc :	14
5. Présentation du Projet GTO :	15
Chapitre 2 : Etat d'avancement du projet	20
Approche I : lexicon-base	20
Résultat final :	20
Approche II : Machine Learning	21
Etape 1 : Importation des bibliothèques	22
Etape 2 : Importation de la base de données	22
Etape 3 : Prétraitement des données	22
Etape 4 : Traitement des données	22
Etape5 : Architecture et formation	22
Conclusion	25
WEBOGRAPHIE	25

Table des figures

FIGURE 1: PRESENTATION DU PROJET	11
Figure 2: Activites de CGI	13
Figure 3: Clients de CGI par secteur	14
Figure 4: Projets GTO	15
FIGURE 5 : FICHE TECHNIQUE DU PROJET GTO	16
Figure 6: Planification du projet	18
Figure 7 : Presentation graphique des scores	20
FIGURE 8: LES APPROCHES DU MACHINES LEARNING	21
Figure 9 : Les couches de notre model	22
Figure 10 : Les couches du model	23
FIGURE 11 : GRAPHE DE LA PRECISION ET PERTE PAR RAPPORT A L'ENSEMBLE	23

Dédicaces

A mes respectueux professeurs

A mes chers parents

A mes chers frères et sœurs

A mes chers amis

A tous ceux qui ont contribués de près ou de loin à la réalisation de ce rapport

Je vous dédie ce travail.

Introduction générale

Facebook est le réseau social le plus consumé dans le monde, il est classé le premier réseau social qui combine toutes les activités proposées dans les autres réseaux sociaux, à savoir la publication des textes, images et vidéo tout en donnant la possibilité d'exprimer librement l'opinion des consommateurs sur une marque ou un personnage public. Sur cette perspective, j'ai planifié de dédier notre projet sur l'analyse sentimental et émotionnel des informations textuelles collectées dans Facebook, cette réalisation permettra de compléter le travail fourni jusqu'à présent et de réaliser une application multitâche, une application qui va traiter tout type de donnée collecté avec une référentiel de type Facebook, tout en donnant un aspect de traçabilité à la solution.

Cette solution est implémenté plus précisément dans tout entreprise ou marque «personnage public » ayant pour but d'évaluer leur performance et de sonder la satisfaction sa clientèle. Mais le cas d'étude que j'ai choisi est consacré à la page officielle de CGI MAROC. Sur ce, j'ai réalisé une présentation de cas d'utilisation de cette solution au sein de cette dernière sur une page de test « @innovationcgimaroc ».




Figure 1: Présentation du projet

Chapitre 1: Présentation de l'entreprise & Contexte générale du projet

Présentation de l'entreprise d'accueil :

I. Introduction

Dans ce chapitre je vais présenter de manière générale le contexte de travail dans lequel ce projet a été effectué.

Tout d'abord Je commencerai par un bref tour d'horizon de l'environnement de stage qui est CGI technologies et solutions, ensuite je présenterai mon projet de fin d'études ainsi que les objectifs qui ont été fixé pour la réalisation de ce dernier.

II. Présentation de CGI technologies et solutions

1. Présentation générale :

est l'acronyme de « conseillers en gestion et informatique », c'est un groupe canadien reconnu pour être parmi les leaders dans le domaine des technologies de l'information et de la communication et en gestion des processus d'affaires. Le groupe a vu le jour en 1976 grâce à Serge Godin et André Imbeau, en tant que petite firme personnelle dans le sous-sol de la résidence de Serge spécialisée dans la consultation informatique pour les administrations et les industriels au Québec.

Grâce à ses 70000 professionnels répartis dans divers emplacements dans le monde, CGI aide ses clients à devenir des organisations numériques centrées sur le client, en offrant des services conseils en management ainsi que des services d'intégration de systèmes de grande qualité. Ces services sont conjugués à plus de 150 solutions de propriété intellectuelle afin d'aider ses clients à devenir des organisations numériques de bout en bout.

CGI se classe parmi les cinq plus grands groupes mondiaux dans son secteur, Groupe CGI fait partie de la liste Forbes Global 2000, un classement des 2000 plus grandes entreprises au monde publié par le magazine économique américain Forbes6. Elle fait également partie du S&P/TSX 60(*indice boursier*), la liste des 60 plus grandes entreprises canadiennes par capitalisation boursière.

Le groupe se caractérise actuellement par son étendue géographique qui englobe les 5 continents, en étant présents dans 40 pays dont le Maroc, tout en conservant un indice de satisfaction client très élevé (9/10). Cet indice de satisfaction est possible grâce entre autres au respect des échéances et des budgets pour plus de 95% des projets.

De plus, parmi les clients de CGI, nous pouvons trouver 39 entreprises du CAC 40(indice boursier) ainsi que de nombreuses grandes entreprises dans le monde entier avec un carnet de commandes de plus de 20 milliards de dollars et un revenu annuel de plus de 10 milliards.



Figure 2: Activités de CGI

2. Principales solutions :

CGI met à profit ses connaissances sectorielles approfondies et son expertise technologique afin de fournir à ses clients des repères dans les dédales, qui constitue la numérisation des ressources humaines, des processus et des technologies. CGI offre une gamme de services dont :

Services conseils-stratégiques en technologie.

Services d'intégration des systèmes.

Développement et gestion des applications.

Services d'infrastructures.

Gestion des processus d'affaires.

Solutions d'affaires exclusives.

3. Clients de CGI:

CGI compte 5000 clients en services complets et 25000 clients en services en gestion des processus d'affaires et propriété intellectuelle. Elle intervient principalement dans les secteurs économiques présents sur la figure ci-dessous :



Figure 3: Clients de CGI par secteur

4. CGI Maroc:

Présente au Maroc depuis 2004, sous le cap de l'ex SSII multinationale Logica, avant d'être réaffecté au Groupe CGI suite à l'absorption de cette dernière pour l'ex-logica. CGI Maroc est une BU de la SBU Fr-Ma-Lu(France-Maroc-Luxembourg), dont les activités se concentrent essentiellement autour de l'offshoring des projets de la SBU Francophone de CGI.

Présente sur 3 sites, à Casa Near Shore, au Technopolis de Rabat et Fès, caractérisée par son modèle de gouvernance inspiré de la norme **ISO 9001**, et par son modèle de sécurité de l'information inspiré également de la norme **ISO 27001**, CGI Maroc assure un nombre considérable des métiers appartenant à la sphère des activités CGI.

CGI Maroc emploi plus de 700 fonctionnels majoritairement issu de formations d'ingénierie ou techniques en relation avec la technologie de l'information pour répondre au besoin des clients avec des solutions robustes.

Les sièges de service de CGI Maroc sont répartis en 3 sièges :

CGI Casablanca : Casa NearShore, Bât. Shore 5, 2ème étage, Casablanca, contient plus que 450 membres et abrite la majorité des projets actifs de CGI Maroc ainsi que les services administratifs.

CGI Rabat : *Technopolis, Bât. Shore 3 Sala El Jadida*, contient plus que 250 membres et abrites quelques extensions de projets situés au site de Casablanca ainsi que des projets propres au site

CGI Fès : Fès Shore Park, Route de Sidi Hrazem.

5. Présentation du Projet GTO:

GTO est l'acronyme de Global Technology Operations, c'est un projet qui a démarré en 2016 sur les 3 sites de CGI Maroc, et qui regroupe l'ensemble des activités techniques et infrastructures de CGI France.

GTO travaille actuellement sur 6 projets à savoir :













Figure 4: Projets GTO

Ces références touchent chaque secteur d'activités auxquels s'adressent le projet GTO :

- o Energie et services
- Manufacturing
- Finance /Banques/ Assurances
- o Retail
- Télécommunications /Transport
- Secteur publique

Ce projet possède une production dédiée aux activités de pilotage des services Infrastructures réseaux et cloud solution.

Projet Collaborateurs	GTO 270 (experts et architectes)
Sites	Casablanca- Rabat-Fès
Certifications	ITIL

Figure 5: Fiche technique du projet GTO

Contexte générale du projet :

Pour faire face aux évolutions accélérées d'un marché de plus en plus concurrentiel et aux nouveaux enjeux en termes de satisfaction de la clientèle, CGI ne cessent de développer leur service et d'intégrer des nouvelles technologies afin d'augmenter leur productivité. Ainsi dans ce sens, la majorité des entreprises se font adapter aux nouvelles technologies de communication, à savoir principalement les réseaux sociaux, des technologies qui font basculer leur marketing vers le digital.

6. Le cadre du projet :

Multiples causes poussent les entrepreneurs à fonder principalement leur marketing sur les réseaux sociaux, d'où un simple avis malveillant, vu et partagé par un groupement de personne, peut affecter le rendement de la production de ces derniers entraînant des pertes financières énormes.

7. Problématique :

A partir du milieu du 20ème siècle, les gens, se sont orientés de plus en plus vers les réseaux sociaux pour exprimer leurs opinions sur les différents sujets du quotidien. Ceci a constitué une source importante – pour les entreprises – de sonder le marché et de se faire une idée précise sur les besoins et les orientations qui l'influencent.

De ce fait ; les entreprises ont déployé des ressources humaines et technologiques de plus en plus performantes, afin de trouver le meilleur outil qui permet de collecter, trier et traiter ces données dans le but d'en tirer le plus de bénéfices possibles.

Alors quelles sont ces solutions optimales qui aident à accéder à cette fin ?

8. Démarche du projet :

L'objectif du présent travail est d'évaluer les caractéristiques auxquelles doivent répondre l'outil de traitement de l'information textuelle sur les réseaux sociaux pour analyser les opinions, et plus précisément les sentiments et les émotions des textes. C'est à dire de fournir l'entièreté des méthodes qui permettent l'analyse sentimental et émotionnel des informations textuelles publiées sur les réseaux sociaux.

Cette étude est réalisée par étapes grâce à une documentation sur l'environnement big data, machine learning, deep learning, une réalisation des applications API des réseaux sociaux choisi. En outre je propose une comparaison entre les différents solutions existantes afin de bien choisir celui à implémenter.

Démarche:

Découverte des environnements, Intelligence artificielle, Big Data, Machine learning,
 Deep learning :

J'ai consacré cette période pour mieux connaître les différents aspects de ces derniers environnements, leurs structure organisationnelle ainsi que l'écosystème dédié à elle ;

Découverte des besoins d'actualité sur le marché :

Cette partie décrit les différents criticité et limites dont le marché doit en répondre, c'était justement la période de la prise de décision du projet réalisé ;

- Réalisation des API et le choix de langage de développement :
 - Cet angle se fait en quatre étapes :
 - Etude sur les réseaux sociaux ayant plus d'impact sur le public
 - Choix des réseaux sociaux
 - Analyse des langages de programmation et les outils les plus

adaptés à ce type de projet

Réalisation des API

- Création de la chaine de connexion et la récupération des access tokens permettant l'accès aux informations textuelles
 - La collecte des données massives
 - Le traitement de l'information textuelle
 - > Proposition d'une interface généralisée :

Le chapitre suivant permet de présenter une solution implémentable dans notre entreprise, de traiter toute information textuelle sélectionnée tout en présentant un ensemble des options supplémentaires qui peuvent aider l'analyse des opinions du public.

- > Etude des différentes solutions existantes
- > Planification des perspectives du projet

9. Planification:

La planification du projet est une phase importante d'avant-projet. Elle consiste à prévoir le déroulement de ce dernier tout au long des phases constituant le cycle de développement. Alors c'est le rôle de diagramme de Gantt (figure ci-dessous) qui permet de visualiser dans le temps les diverses tâches composant un projet, la figure suivante présente le planning de mon stage.




Figure 6: Planification du projet

Conclusion

Ce chapitre m'a permis de bien délimiter le projet et d'avoir une vision plus claire du sujet. J'ai décrit les besoins fonctionnels.

Par la suite, il m'a permis de planifier et organiser le temps consacré à la réalisation du projet en identifiant les sprints. Dans le chapitre suivant, nous allons entamer la phase d'étude préliminaire.

Chapitre 2: Initialisation du projet

Ce projet porte sur un domaine très vaste, le traitement du langage naturel est un mélange entre l'informatique, la linguistique et les apprentissages automatiques. Son but principale est d'interpréter le langage humain en langage machine.

Suite aux recherches et études réalisées, j'ai opté pour deux grandes approches :

Approche I: lexicon-base

Est une approche qui consiste a utilisé un corpus* ou un dictionnaire, qui m'offre une quantité des mots en langue française avec leurs score (positif, négatif) et réactions sentimentales (tristesse, joie, surprise, dégout, confiance et la peur).

Dès que je récupère tous les données collectées par les API, je me base sur le dictionnaire pour traiter et analyser nos textes.

Les lexicons les plus répandus sont :WordNet, SentiWord, AFINN, NRC

Résultat final:

Analyse sentimentalle des commentaires sur la page facebook CGI




Figure 7 : Présentation graphique des scores

Approche II: Machine Learning

C'est une approche qui se base sur les techniques du machine learning (Apprentissage automatique).

Dans cette approche souvent deux grands catégories :

L'apprentissage supervisé : est une technique d'apprentissage automatique où l'on cherche à produire automatiquement des règles à partir d'une base de données étiquetées(labellisées) contenant des exemples déjà traités et validés.

L'apprentissage non supervisé : est une technique d'apprentissage automatique qui ne se base pas sur des exemples déjà traités et validés, il prend uniquement des données sans étiquettes.




Figure 8: Les approches du machines learning

Dans ce projet, j'ai opté une sous-catégorie d'apprentissage supervisé qui est : l'apprentissage approfondi (Deep Learning)

Le deep learning est une branche d'apprentissage automatique qui s'appuie sur des réseaux de neurones artificiels par l'utilisation des centaines voire même des milliers de couches cachées.

Le but du projet est l'analyse sentimentale des commentaires sur Facebook en langue Française, en revanche, mon premier teste a été effectué sur une base de données (IMBD movie) labellisées en Anglais.

Les lignes suivante, expliquent les étapes de la réalisation de mon modèle :

Etape 1 : Importation des bibliothèques

J'ai utilisé une dizaine de bibliothèques qui offrent une panoplie d'outils comme :

- NLTK: permet d'effectuer une série d'opération sur traitement des langages naturels
- Pandas, Numpy, Matplot, Scipy :effectuent des calculs scientifiques, la manipulation et l'affichage des données
- Sklearn : effectue les opération de prétraitements de données.

Etape 2 : Importation de la base de données

Cette étape consiste à importer la base de données IMDB, comporte 25K commentaires avec deux catégories : les données étiquetées positivement et négativement qui provient des commentaires laissés sur les films.

Etape 3 : Prétraitement des données

Dans cette phase j'ai effectué des tâches de nettoyage, de régularisation et de mise en forme

Etape 4 : Traitement des données

Ensuite, j'ai extrait 10000 caractéristiques sur l'ensemble de texte à l'aide de la technique du TF-IDF (Term Frequency Inverse Document Frequency)

Etape5: Architecture et formation




Figure 9 : Les couches de notre model

Ce modèle comporte 6 couche, dont la couche d'entrée prend 5000 commentaires.

Et pour les hyper-paramètres, existent :

- Activations : la fonction tanh à l'entrées et la fonction sigmoid à la couche de sortie
- o **Optimisation**: la fonction d'Adam
- o **Perte**: la fonction cross-entropy

La figure ci-dessous illustre le résultat de la formation de notre modèle

Figure 10 : Les couches du model

Je remarque que, le modèle fournit une précision de 0.87 et une perte de 0.3315 donné Sur ce graphe, on a deux ensemble




Figure 11 : Graphe de la précision et perte par rapport à l'ensemble

La partie supérieur du graphe d'écrit :

- La courbe orange d'écrit la précision de l'ensemble de validation par rapport à la quantité de données passés au modèle.
- La courbe bleu d'écrit la précision de l'ensemble d'entrainement par rapport à la quantité de données passés au modèle.

La partie inférieur du graphe d'écrit:

- La courbe rouge d'écrit la perte de l'ensemble de validation par rapport à la quantité de données passés au modèle.
- La courbe verte d'écrit la perte de l'ensemble d'entrainement par rapport à la quantité de données passés au modèle.

Jusqu'à ce point j'ai eu une base de données française étiquetées, dont je suis en cours de prétraitement (nettoyage, suppression des mot vide, régularisation)

Afin de clore, mon projet, il me reste que deux grands étapes :

- Le stockage des données : les machines learning étant des gigantesque nie de données et des gros consommateurs d'espace, on souhaiterait stocké seulement les données finalisé dans une base de données No SQL(Cassandra, Mongo DB) ce choix est due à leur accès rapide par rapport aux base de données SQL
- La visualisation : dans ce projet, j'ai souhaiterai visualiser mes données sur Kibana, en raison de sa maniabilité et CGI dispose la licence afin de minimiser les coûts dû à l'achat d'un autre outil de visualisation.

L'affichage se passera en deux formes :

L'affichage des émotions (j'aime, j'adore, je déteste, je suis excité, je suis surpris, je suis triste, je suis énervé) des utilisateurs sur les différents publications de la page Facebook de CGI

L'affichage des sentiments détectés dans le contenu des commentaires des utilisateurs, c'est-à-dire par rapport à une publication posté par CGI, est ce que l'état émotionnelle de ces clients sont négatif ou positif face à cette publication ?

Conclusion

Toute étude technique est un processus avec des étapes complexes qui comporte de nombreuses itérations, afin de résoudre efficacement le problème en question.

Ce projet en cours de réalisation fait bien l'objet d'une étude approfondit sur l'analyse sentimentale et la détection émotionnel des commentaires sur la page Facebook de CGI, qui est aujourd'hui une pièce incontournable des géants industriels, la satisfaction clientèle a toujours été l'un des objectifs principal des entreprises mais avec l'ère des Big Data, je peux obtenir l'avis de mes clients via nos pages des réseaux sociaux, d'où analyser ces sentiments peut permettre à une entreprise d'avoir une vue globale sur la satisfaction de ses clients.

Le déroulement de ce projet s'inscrit dans trois phases : tout d'abord la collecte des données via des applications réaliser par les APIs et le nettoyage (suppression des mots vides, normalisation, régularisation, et la mise en forme) des données est une étape très cruciale dans tout projet de Big Data, ensuite le choix des approches (lexicons et machine learning) et les modèles (apprentissage supervisé approfondi) approprié à nos besoins , enfin le stockage(qui sera réaliser soit sur Cassandra ou Mongo DB vu leur élasticité et leur rapidité) et la visualisation (Kibana) qui sont en cours de réalisation.

WEBOGRAPHIE

HTTPS://FR.WIKIPEDIA.ORG/WIKI/APPRENTISSAGE_PROFOND

HTTPS://FR.WIKIPEDIA.ORG/WIKI/APPRENTISSAGE_AUTOMATIQUE

HTTPS://WWW.NLTK.ORG/

HTTPS://WWW.ELASTIC.CO/FR/PRODUCTS/KIBANA